PROJET CHURN — Analyse du Drift et Stratégie d'Adaptation

1. Introduction

L'objectif de ce projet est d'analyser l'impact du data drift sur un modèle de prédiction du churn et d'évaluer différentes stratégies d'adaptation temporelle. Nous étudions successivement le drift des données, son impact sur les performances, la comparaison de modèles et l'optimisation économique de la décision.

2. Analyse du Drift et impact sur les performances

L'analyse exploratoire met en évidence un drift progressif des données, caractérisé par une augmentation du taux de churn, une évolution de la part des contrats mensuels ainsi qu'une modification des distributions de certaines variables numériques.

Ces observations soutiennent l'hypothèse métier selon laquelle le comportement des clients évolue dans le temps, modifiant progressivement la structure du portefeuille et les déterminants du churn. Elles suggèrent également que les mécanismes générateurs des données ne sont pas stationnaires.

Le monitoring temporel des performances révèle une dégradation progressive des modèles figés, confirmant que ce drift impacte directement la capacité prédictive et la généralisation du modèle. Cette dégradation valide l'hypothèse selon laquelle un modèle entraîné sur des données historiques peut devenir partiellement obsolète si aucune stratégie d'adaptation n'est mise en place.

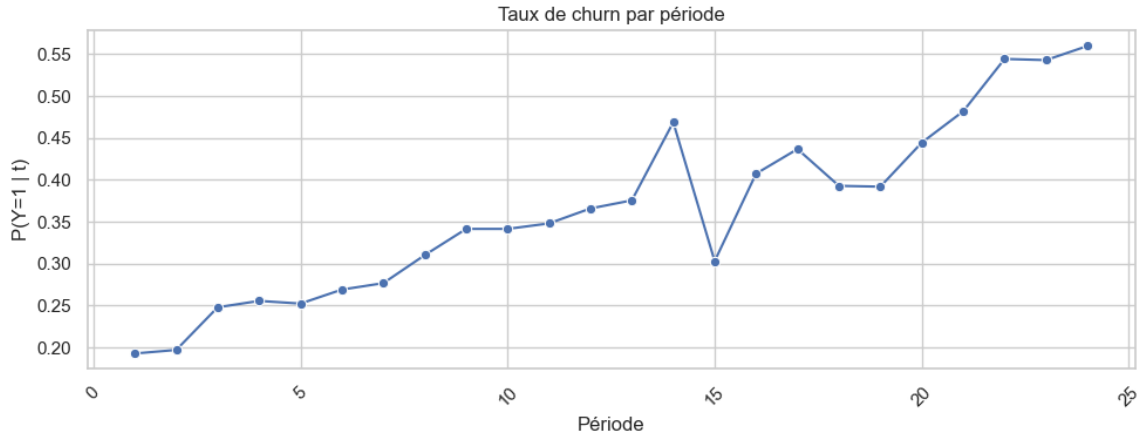

3. Comparaison de modèles

Deux modèles ont été comparés : une Régression Logistique (modèle linéaire) et une Random Forest (modèle non linéaire).

L'évaluation s'est principalement focalisée sur l'AUC-ROC, métrique privilégiée dans ce contexte pour plusieurs raisons : elle mesure la capacité de discrimination du modèle

indépendamment d'un seuil de décision et reste robuste aux variations du taux de churn observées dans le temps. Contrairement à l'accuracy, l'AUC n'est pas affectée par un éventuel déséquilibre des classes ni par un choix arbitraire de seuil.

La Random Forest, avec une profondeur contrôlée (max_depth = 3) afin de limiter le sur-apprentissage, améliore légèrement la performance en termes d'AUC (+0.9% par rapport à la logistique). Cette amélioration suggère la présence de relations partiellement non linéaires entre les variables explicatives et le churn.

Par ailleurs, la stratégie de ré-entraînement rolling améliore les performances pour les deux modèles, confirmant que le drift observé nécessite une adaptation temporelle régulière.

Le meilleur compromis performance/robustesse est obtenu avec la Random Forest en stratégie rolling (AUC ≈ 0.878), qui constitue la solution retenue.

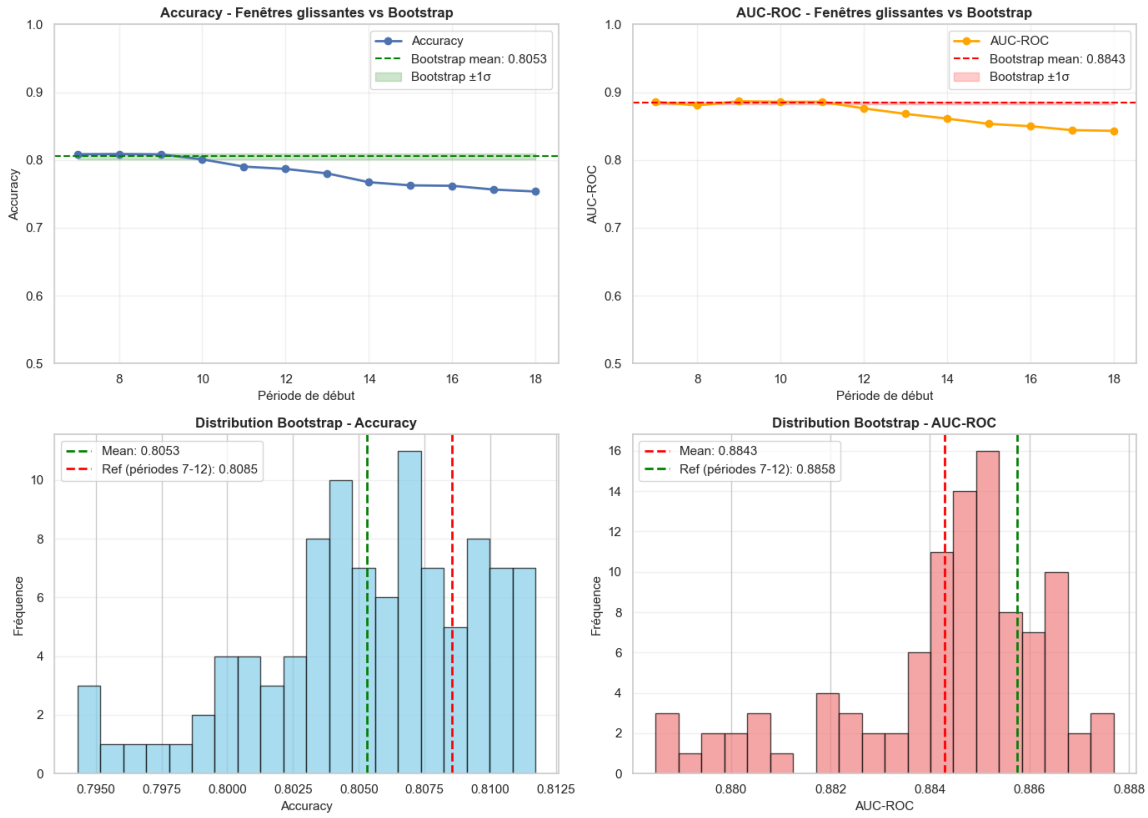

4. Stratégie de réentraînement et choix de w

Un backtesting a été réalisé sur différentes tailles de fenêtre d'historique $w \in \{2,3,4,6,9,12\}$afin d'identifier le compromis optimal entre capacité d'adaptation au drift et stabilité statistique.

Des fenêtres courtes permettent une adaptation rapide aux évolutions récentes, mais au prix d'une variance plus élevée liée à un volume d'apprentissage réduit. À l'inverse, des fenêtres plus longues offrent une meilleure stabilité en intégrant davantage d'information historique, mais peuvent devenir moins réactives en cas de drift brutal.

Les résultats montrent que $w = 12$ maximise l'AUC moyenne tout en présentant la plus faible variabilité, indiquant que le drift observé est progressif plutôt que structurellement abrupt. Conserver un historique plus long permet ainsi d'améliorer la robustesse du modèle sans perte significative d'adaptabilité.

Recommandation : mettre en place un réentraînement mensuel basé sur les 12 dernières périodes, afin de maintenir un équilibre optimal entre stabilité et adaptation au drift.

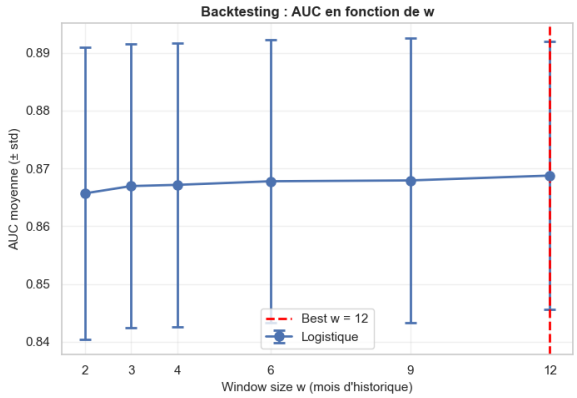

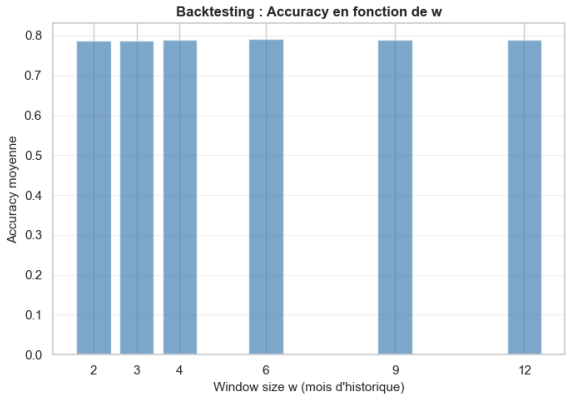

5. Optimisation du Seuil et Coût Métier

L'optimisation du seuil de décision repose sur une fonction de coût métier définie par une asymétrie des erreurs : Faux Négatif (FN) = 100 € et Faux Positif (FP) = 40 €. Cette asymétrie reflète le fait qu'un churner non détecté génère une perte économique plus importante qu'une action commerciale inutile.

Contrairement au seuil standard de 0.5, qui est arbitraire et ne tient pas compte des coûts métier, l'optimisation consiste à rechercher le seuil minimisant le coût total $C = 100 \times FN + 40 \times FP$. Le seuil optimal global estimé à 0.077 permet ainsi une réduction significative du coût total (≈ 36,5 %), démontrant que la décision économique optimale diffère fortement de la décision statistique standard.

Toutefois, l'analyse rolling met en évidence une variabilité importante du seuil optimal au fil du temps. Cette instabilité s'explique par l'évolution de la distribution des probabilités prédites et du taux de churn, conséquence directe du drift observé.

Ces résultats suggèrent qu'un seuil fixe peut devenir sous-optimal dans un environnement non stationnaire. Une stratégie de recalibration périodique du seuil est donc recommandée en production afin d'aligner en permanence la décision algorithmique avec les objectifs économiques.

.

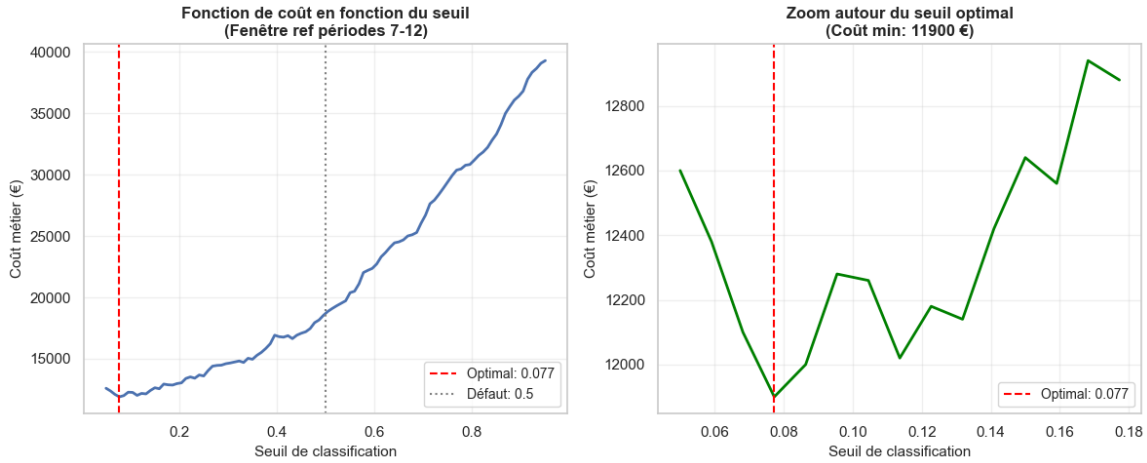

6. Conclusion et Recommandations

Le projet démontre que le drift impacte significativement les performances des modèles figés, dont la capacité de généralisation se dégrade progressivement. La stratégie de ré-entraînement rolling améliore la robustesse en adaptant le modèle aux évolutions temporelles.

La Random Forest, avec profondeur contrôlée (max_depth = 3), offre le meilleur compromis performance/stabilité. Par ailleurs, l'optimisation du seuil montre que la décision optimale dépend des coûts métier et peut varier dans le temps, justifiant une recalibration périodique.

Stratégie recommandée :
Random Forest (max_depth = 3), ré-entraînée mensuellement sur les 12 dernières périodes (w = 12), avec recalibration régulière du seuil.